

MODELADO DE LA PROPAGACIÓN DE EPIDEMIAS EN REDES DINÁMICAS USANDO TEORÍA DE GRAFOS

Juan Felipe Amaya, Juan Felipe Rojas, Sebastian Sanchez
Matemáticas Aplicadas y Ciencias de la Computación, Universidad del Rosario

Resumen—En este trabajo se modela la propagación del COVID-19 mediante un proceso SIS sobre redes temporales, donde los contactos entre individuos varían en el tiempo. Representamos la red como una secuencia de snapshots $\{G_t\}$ y empleamos TBFS para estimar el tiempo mínimo de llegada y el alcance del contagio respetando la causalidad temporal. Adicionalmente, comparamos estos resultados con un grafo agregado utilizando DIJKSTRA para identificar el sesgo introducido al ignorar la dimensión temporal. Este enfoque permite analizar cómo la estructura y evolución de la red influyen en la dispersión del COVID-19, sentando las bases para la simulación computacional en la siguiente etapa del proyecto.

Index Terms—Grafos, Redes temporales, Propagación de epidemias, SIS, Caminos de menor costo

I. INTRODUCCIÓN

La propagación de epidemias, tanto en contextos biológicos como digitales, ha sido un fenómeno ampliamente estudiado debido a su impacto en la sociedad. Tradicionalmente, los modelos epidemiológicos se basan en redes estáticas, donde las interacciones entre los individuos permanecen constantes en el tiempo. Sin embargo, en la realidad, las conexiones entre personas cambian dinámicamente: nuevas interacciones aparecen mientras otras desaparecen. La teoría de grafos proporciona un marco adecuado para modelar este tipo de sistemas, representando a los individuos como nodos y sus interacciones como aristas. El análisis de epidemias en redes dinámicas permite comprender mejor la propagación de enfermedades, la difusión de información en redes sociales o la expansión de virus informáticos. Este proyecto propone aplicar conceptos de la teoría de grafos para modelar y analizar la propagación de epidemias en redes dinámicas, con el fin de sentar las bases para una posterior implementación computacional.

II. DESCRIPCIÓN DEL PROBLEMA

El problema a estudiar consiste en determinar cómo evoluciona la propagación de una epidemia cuando las conexiones entre los individuos no son fijas, sino que varían con el tiempo. A diferencia de los modelos tradicionales en redes estáticas, en una red dinámica los nodos pueden modificar sus vecinos, lo que introduce mayor complejidad en el análisis. Este fenómeno es relevante en distintos ámbitos. En la salud pública, permite comprender la propagación de enfermedades en sociedades donde las interacciones cambian constantemente. En el ámbito digital, ayuda a estudiar la diseminación de virus o ataques en

redes de computadores que no son permanentes. Asimismo, en redes sociales ofrece un marco para entender cómo la información, rumores o noticias falsas se esparcen entre usuarios conectados temporalmente.

III. OBJETIVOS

III-A. Objetivo general

Modelar y analizar la propagación de epidemias en redes dinámicas mediante teoría de grafos.

III-B. Objetivos específicos

- Representar matemáticamente una red dinámica mediante nodos y aristas variables en el tiempo.
- Adaptar un modelo epidemiológico clásico (SIS) al contexto de redes dinámicas.
- Identificar cómo los cambios en la estructura de la red afectan la velocidad y el alcance de la propagación.
- Diseñar y ejecutar una simulación computacional que ilustre el fenómeno.

IV. MARCO TEÓRICO

IV-A. Grafos y redes temporales

En este trabajo se modela la interacción entre individuos mediante *redes temporales*, donde la estructura del grafo varía a lo largo del tiempo. Consideramos una familia

$$\mathcal{G} = \{G_t = (V, E_t)\}_{t=1}^T,$$

en la cual las aristas representan contactos que ocurren en instantes específicos. Este enfoque permite capturar simultáneamente la topología y la secuencia temporal de las interacciones, elementos esenciales para el estudio de procesos epidémicos en redes dinámicas (Holme y Saramäki, 2012; Newman, 2010).

La matriz de adyacencia A en el caso temporal, la noción central que preserva es la de *camino que respeta el tiempo*: una secuencia $(v_0, t_0) \rightarrow (v_1, t_1) \rightarrow \dots \rightarrow (v_k, t_k)$ con $t_0 \leq t_1 \leq \dots \leq t_k$ y $(v_{i-1}, v_i) \in E_{t_i}$. Esta noción permite definir la *alcanzabilidad temporal* y los *tiempos de primera llegada*, esenciales para cuantificar la propagación (Holme y Saramäki, 2012).

IV-B. Modelos epidémicos en redes

Los modelos epidemiológicos permiten describir matemáticamente la propagación de enfermedades infecciosas mediante reglas que capturan la transmisión, la recuperación y la interacción entre individuos (Kiss, Miller, y Simon, 2017). En el contexto de redes, estos modelos representan la dinámica del contagio sobre una estructura de contactos, donde la topología influye directamente en la velocidad y el alcance de la propagación.

En este trabajo consideramos el modelo **SIS** (susceptible–infectado–susceptible) (Pastor-Satorras, Castellano, Van Mieghem, y Vespignani, 2015), adecuado para patologías con posibilidad de reinfección. En SIS, cada individuo puede encontrarse en uno de dos estados: susceptible (S), cuando es vulnerable al contagio, o infectado (I), cuando porta el virus y puede transmitirlo. En tiempo discreto, para un contacto $(u, v) \in E_t$ con $u \in I_t$ y $v \in S_t$, la infección ocurre con probabilidad β , mientras que cada infectado retorna al estado susceptible con probabilidad δ , reflejando la ausencia de inmunidad permanente.

En redes estáticas, un umbral epidémico aproximado para SIS viene dado por

$$\tau_c \approx \frac{1}{\lambda_{\max}(A)} \quad \text{con} \quad \tau = \frac{\beta}{\delta},$$

donde $\lambda_{\max}(A)$ es el radio espectral de la matriz de adyacencia (Van Mieghem, 2011). En redes temporales, dicho umbral depende además de la sincronización de los contactos, puesto que muchos caminos presentes en el grafo agregado no corresponden a rutas causales reales en el tiempo (Holme y Saramäki, 2012; Masuda y Lambiotte, 2016).

IV-B1. COVID–19 como proceso SIS en redes dinámicas: El COVID–19 presenta posibilidad de reinfección debido a la pérdida de inmunidad y a la aparición de nuevas variantes (Harvey, Carabelli, Jackson, y cols., 2021). Por ello, su dinámica puede modelarse mediante un proceso *Susceptible–Infectado–Susceptible* (SIS), en el cual un individuo recuperado retorna al estado susceptible y permanece expuesto a contagios posteriores. Dado que la transmisión depende directamente de contactos cambiantes en el tiempo, las redes dinámicas constituyen un marco adecuado para describir la propagación del COVID–19 en entornos sociales reales (Liu, Gayle, Wilder-Smith, y Rocklöv, 2020).

IV-C. Agregación temporal y sesgos

Para comparar una red temporal con una representación estática, se construye un grafo agregado $G^{(\Delta t)} = (V, E^*)$ uniendo contactos que ocurren dentro de ventanas de tamaño Δt . En $G^{(\Delta t)}$ el peso $w(u, v)$ puede definirse como el *número de encuentros* o el *tiempo total de exposición* entre u y v . Ventanas muy grandes tienden a *sobreestimar* la conectividad efectiva (crean caminos no causales), mientras que ventanas demasiado pequeñas *subestiman* la conectividad al fragmentar en exceso la red (pueden cortar caminos viables) (Holme y

Saramäki, 2012). El presente trabajo contrasta métricas epidémicas en el grafo temporal frente al agregado para distintos valores de Δt .

IV-D. Caminos temporales y algoritmos

La propagación en redes dinámicas se apoya en *caminos temporales*, donde cada contacto ocurre en un instante no anterior al previo. Para estudiar la alcanzabilidad y el tiempo mínimo de llegada empleamos TBFS (Temporal Breadth–First Search), una variante temporal de BFS que recorre la secuencia de snapshots $\{E_t\}$ respetando la causalidad temporal (Holme y Saramäki, 2012). Su complejidad es $O(\sum_t |E_t|)$, ya que cada contacto se explora a lo sumo una vez.

Con el fin de contrastar este comportamiento con un escenario estático, se construye un grafo agregado $G(\Delta t)$ y se aplica DIJKSTRA para obtener caminos mínimos ponderados, donde los pesos representan la duración o intensidad del contacto (Newman, 2010). Esto permite comparar el alcance y los tiempos de llegada entre la red dinámica y su versión agregada, cuantificando el sesgo introducido al ignorar la dimensión temporal.

IV-E. Caminos causales y tiempos mínimos de llegada

En redes temporales, no todos los caminos del grafo agregado corresponden a rutas factibles de contagio: solo aquellos que respetan la secuencia de tiempos constituyen *caminos causales*. Para medir la rapidez con que una infección puede alcanzar cada nodo, se estudian los *earliest-arrival paths*, es decir, rutas que minimizan el tiempo de llegada (Bui-Xuan, Ferreira, y Jarry, 2003; Casteigts, Flocchini, Quattrociocchi, y Santoro, 2012).

El algoritmo TBFS implementado en este trabajo es una versión temporal de BFS que opera por capas cronológicas. Dado un nodo fuente infectado en t_0 , el algoritmo:

1. explora únicamente contactos en instantes $t' \geq t$,
2. garantiza que cada relajación respete el orden temporal,
3. y asigna a cada nodo v un tiempo $\tau(v)$ que corresponde al instante más temprano en que puede ser alcanzado.

Estos valores permiten cuantificar el alcance del brote bajo restricciones temporales estrictas, diferenciándose de los tiempos obtenidos en un grafo agregado con DIJKSTRA, que ignoran la dimensión temporal y pueden subestimar los tiempos por la aparición de caminos no causales.

IV-F. Grafo de contagios dirigido

Además de la red temporal original, es posible construir un *grafo de contagios*, estructura dirigida que representa explícitamente quién contagió a quién. Definimos:

$$G^{\text{inf}} = (V, E^{\text{inf}}),$$

donde $(u, v) \in E^{\text{inf}}$ si y solo si el individuo u infectó a v por primera vez en el tiempo $t_{\text{infect}}(v)$. Esta representación, utilizada en estudios de difusión causal y análisis de rutas de transmisión (Holme, 2015; Rocha y Masuda, 2016), permite visualizar el brote como un árbol o DAG (grafo acíclico

dirigido), donde cada arista captura un evento de contagio con dirección y sello temporal.

El grafo de contagios facilita:

- estudiar rutas de transmisión efectivamente utilizadas,
- aplicar centralidades dirigidas como PageRank,
- identificar supercontagiadores,
- y comparar la estructura causal con la red de contactos original.

IV-G. Centralidad y nodos influyentes en la propagación

El estudio de medidas de centralidad en redes es fundamental para identificar nodos que desempeñan un papel crítico en la difusión de enfermedades. En epidemias, los individuos más importantes no siempre son aquellos con mayor número de contactos, sino aquellos que ocupan posiciones estructurales que facilitan rutas de transmisión (Borgatti, 2005; Kitsak, Gallos, Havlin, y cols., 2010).

Diversas medidas permiten capturar este fenómeno:

- **Centralidad de grado:** identifica a los individuos con mayor número de contactos. Aunque es una medida local, puede correlacionarse con la capacidad de iniciar brotes epidémicos.
- **Betweenness:** cuantifica cuántos caminos pasan por un nodo, identificando “puentes” críticos para conectar comunidades.
- **Eigenvector:** asigna mayor importancia a nodos conectados con otros nodos influyentes, capturando efectos jerárquicos.
- **PageRank:** especialmente útil en redes dirigidas, asigna importancia según la relevancia de quienes apuntan hacia un nodo (Brin y Page, 1998). En el contexto epidémico, refleja la probabilidad de llegar a un nodo siguiendo trayectorias de contagio.

En este proyecto, estas métricas permiten identificar individuos estructuralmente relevantes y evaluar su papel en la propagación del COVID-19 dentro de la red dinámica.

IV-H. Implicaciones para el diseño experimental

De la teoría anterior se desprenden dos lineamientos que guían nuestra metodología: (i) reportar resultados *temporal vs. agregado* para cuantificar el sesgo por ignorar el tiempo; y (ii) explorar la sensibilidad en $(\beta, \delta, \Delta t)$ para mapear el umbral y su variación.

MODELAMIENTO DEL PROBLEMA

V. MODELADO DEL GRAFO

Para representar la estructura de contactos que da lugar a la propagación epidémica, consideramos una *red temporal ponderada y no dirigida*. El conjunto de individuos se modela mediante un conjunto fijo de vértices V , mientras que las interacciones varían en el tiempo a través de una familia de grafos

$$\mathcal{G} = \{G_t = (V, E_t, w_t)\}_{t=1}^T,$$

donde $E_t \subseteq \{\{u, v\} : u, v \in V, u \neq v\}$ denota el conjunto de contactos activos en el instante t y $w_t : E_t \rightarrow \mathbb{R}^+$ asigna un

peso positivo a cada interacción. El peso $w_t(u, v)$ representa la intensidad o duración del contacto entre los individuos u y v en el tiempo t , lo cual captura la variabilidad temporal de la exposición y su impacto potencial en la transmisión.

El uso de un grafo no dirigido refleja que el contacto físico es bidireccional, mientras que la ponderación permite distinguir interacciones más relevantes epidemiológicamente. Para efectos computacionales, la red se representa mediante listas de adyacencia en cada G_t , lo cual reduce el costo espacial y optimiza los recorridos, dado que la red es dispersa en comparación con $|V|^2$.

V-A. Red dinámica

En una red temporal, la estructura de contactos evoluciona a lo largo del tiempo, haciendo que la propagación dependa tanto de la conectividad como del instante en que ocurren las interacciones. Para capturar este comportamiento, la dinámica se describe mediante la familia $\mathcal{G} = \{G_t\}_{t=1}^T$, donde cada G_t contiene únicamente los contactos activos en el tiempo t .

La difusión epidémica sólo puede seguir *caminos temporales*, definidos como secuencias

$$(v_0, t_0) \rightarrow (v_1, t_1) \rightarrow \dots \rightarrow (v_k, t_k), \quad t_0 \leq t_1 \leq \dots \leq t_k,$$

tales que $\{v_{i-1}, v_i\} \in E_{t_i}$ para todo i . Esta restricción garantiza la causalidad temporal del proceso: un contagio no puede transmitirse a través de contactos que, aunque existan en el grafo agregado, no ocurren en el orden correcto en la red dinámica.

Para efectos comparativos, es común construir un grafo agregado $G(\Delta t)$ uniendo los contactos que ocurren dentro de ventanas temporales de tamaño Δt . Sin embargo, valores grandes de Δt tienden a sobreestimar la conectividad efectiva al introducir caminos no causales, mientras que valores demasiado pequeños fragmentan la red y subestiman el alcance del contagio. La incorporación explícita del tiempo evita estos sesgos y permite analizar la propagación de forma más realista.

VI. MODELO EPIDEMIOLÓGICO

El proceso de contagio se modela específicamente para el COVID-19, enfermedad caracterizada por su alta transmisibilidad, posibilidad de reinfección y dependencia directa del contacto cercano entre individuos (Liu y cols., 2020). Diversos estudios han mostrado que, incluso tras una recuperación, un individuo puede volver a contagiarse debido a la disminución de la inmunidad y a la aparición de nuevas variantes (Harvey y cols., 2021), lo cual hace apropiado el uso de un modelo *Susceptible–Infectado–Susceptible* (SIS) en escenarios donde la reinfección es relevante.

Consideramos un modelo SIS en tiempo discreto sobre la red temporal $\mathcal{G} = \{G_t\}$. Cada individuo $v \in V$ puede encontrarse en uno de dos estados: susceptible (S), cuando es vulnerable al contagio, o infectado (I), cuando porta el virus y puede transmitirlo. El conjunto de nodos infectados en el tiempo t se denota por I_t .

El COVID-19 se transmite mediante contacto cercano. Por ello, un nodo susceptible v puede infectarse en el tiempo

$t + 1$ si mantiene contacto con vecinos infectados en $G_t = (V, E_t, w_t)$. La probabilidad de infección está controlada por un parámetro $\beta \in (0, 1)$ que representa la tasa de transmisión del virus. Formalmente:

$$P(v \in I_{t+1}) = 1 - \prod_{\{u,v\} \in E_t} (1 - \beta w_t(u, v) \mathbf{1}_{\{u \in I_t\}}),$$

donde $w_t(u, v)$ representa la intensidad o duración del contacto entre u y v en el instante t .

Por otra parte, un individuo infectado retorna al estado susceptible con probabilidad $\delta \in (0, 1)$, modelando el fin de la infección activa y la ausencia de inmunidad permanente. El nodo queda nuevamente expuesto a contagios posteriores, cerrando el ciclo $S \rightarrow I \rightarrow S$.

Este modelo captura tres rasgos epidemiológicos clave del COVID-19: (i) la transmisión dependiente de contactos dinámicos en el tiempo, (ii) la posibilidad de reinfección, y (iii) la variabilidad del riesgo según la intensidad de las interacciones sociales.

SOLUCIÓN PROPUESTA

VII. ALGORITMOS Y COMPLEJIDAD

VII-A. Problema objetivo

Consideramos dos objetivos principales sobre la red temporal $\mathcal{G} = \{G_t = (V, E_t, w_t)\}_{t=1}^T$:

1. **Tiempo mínimo de llegada (earliest arrival).** Dado un conjunto inicial de infectados I_0 , calcular el menor tiempo $\tau(v)$ en el que cada nodo $v \in V$ puede ser alcanzado por la infección a través de *camino temporal* que respeten el orden cronológico de los contactos.
2. **Alcance temporal del contagio.** Estimar el número de nodos alcanzados por la infección hasta un horizonte T (o bien, por capas temporales), partiendo de I_0 .

Estos objetivos permiten cuantificar la velocidad y extensión de la propagación bajo la dinámica realista de contactos variables en el tiempo y, posteriormente, contrastarlos con un grafo agregado $G(\Delta t)$ para estudiar el sesgo por ignorar la dimensión temporal.

VII-B. Algoritmo seleccionado: BFS temporal (TBFS)

Para ambos objetivos empleamos una variante de *BFS* sobre redes temporales (TBFS), que explora la secuencia $\{E_t\}$ en orden de tiempo y respeta la *causalidad temporal* (Holme y Saramäki, 2012; Masuda y Lambiotte, 2016). Mantendremos un vector de tiempos de llegada $\tau(\cdot)$ inicializado con $+\infty$ y una cola que opera por *capas temporales*:

- **Inicialización:** Para $v \in I_0$, fijar $\tau(v) = 0$ e insertar $(v, 0)$ a la cola.
- **Expansión temporal:** Al extraer (u, t) , se relajan sólo contactos activos en $E_{t'}$ con $t' \geq t$ (generalmente $t' = t$ en tiempo discreto); para cada $\{u, v\} \in E_{t'}$, si $\tau(v) = +\infty$, asignar $\tau(v) = t'$ e insertar (v, t') en la cola.
- **Alcance:** El conjunto $\{v : \tau(v) \leq T\}$ determina el alcance hasta el horizonte T ; los valores $\tau(v)$ son los tiempos mínimos de llegada.

Pesos $w_t(u, v)$. Al ser un BFS (no ponderado en el eje temporal), w_t no altera el *orden* de llegada, pero sí puede incorporarse de dos modos: (i) como umbral para considerar una arista “activa” (p.ej., $w_t \geq \theta$), o (ii) en simulaciones Monte Carlo del modelo SIS (probabilidad de infección βw_t al visitar la arista). En este trabajo, empleamos TBFS para *tiempos mínimos de llegada/alcance* y, por separado, el modelo SIS para *probabilidad de infección*, manteniendo clara la distinción entre *accesibilidad temporal* y *dinámica epidemiológica*.

```
Input: snapshots {E_t}_t=0^T, seed set I_0
tau[v] <- +inf for all v in V
for v in I_0: tau[v] <- 0; push (v, 0)
while queue not empty:
    (u, t) <- pop()
    for each contact {u, v} in E_t:
        if tau[v] == +inf:
            tau[v] <- t
            push (v, t)
Output: tau, and Reach(T) = |{ v : tau[v] <= T }|
```

VII-C. Complejidad

La implementación sobre *snapshots* evita construir la red expandida en el tiempo (de tamaño $\Theta(|V|T)$). El costo de TBFS viene dominado por el número total de contactos procesados:

$$\mathcal{O}\left(\sum_{t=1}^T |E_t|\right),$$

más el manejo de colas y marcados $\mathcal{O}(|V|)$. Esta cota es óptima en el modelo de exploración por instantes, pues cada contacto potencial se considera a lo sumo una vez (Holme y Saramäki, 2012). En contraste, un enfoque de *time-expansion* explícito tiene complejidad en el mismo orden de aristas pero con sobre costo espacial $\Theta(|V|T)$ (Newman, 2010).

VII-C1. Comparativo con grafo agregado.: Para $G(\Delta t)$ no dirigido es posible aplicar algoritmos estándar de caminos mínimos en grafos estáticos (por ejemplo BFS en el caso no ponderado), obteniendo distancias geodésicas en la red agregada. No obstante, estos resultados tienden a *sobreestimar* accesibilidad y subestimar tiempos de llegada respecto a la red temporal cuando Δt es grande, al introducir caminos no causales (Holme y Saramäki, 2012; Masuda y Lambiotte, 2016).

VIII. IMPLEMENTACIÓN COMPUTACIONAL Y SIMULACIÓN

En esta sección describimos cómo se implementó el modelo SIS sobre la red temporal de contactos, la construcción del grafo de contagios dirigido y los experimentos adicionales de alcanzabilidad temporal y sesgo por agregación. Toda la implementación se realizó en Python utilizando principalmente las librerías *pandas* y *networkx*, organizadas en scripts dentro de *src/* y un cuaderno interactivo *sis_animacion.ipynb*.

VIII-A. Conjunto de datos y preprocesamiento

Como red de contactos utilizamos el conjunto de datos *High school dynamic contact networks* del proyecto SocioPatterns, que registra interacciones cara a cara entre estudiantes de un colegio de educación secundaria durante varios días. Cada contacto se observa como un par de identificadores anónimos y un sello temporal continuo en segundos.

En una etapa previa de preprocesamiento se generaron dos archivos en la carpeta `data/processed/`:

- `nodes.csv`, con las columnas:
 - `id`: identificador del individuo (que se trata como cadena),
 - `label`: etiqueta textual (igual a `id`),
 - `group`: posible atributo de grupo (curso, etc.), que en nuestro caso no se usa explícitamente.
- `contacts.csv`, con las columnas:
 - `source, target`: nodos que entran en contacto,
 - `t_start, t_end`: ventana temporal discreta en la que el contacto está activo,
 - `weight`: duración total del contacto en segundos,
 - `directed`: indicador de direccionalidad (en nuestro caso siempre `False`).

Para pasar del tiempo continuo (segundos) a tiempo discreto se fija una resolución temporal $\Delta t = 20$ s. Si un contacto comienza en un tiempo t con duración d , se asignan

$$t_{\text{start}} = \left\lfloor \frac{t - t_0}{\Delta t} \right\rfloor + 1, \quad t_{\text{end}} = \left\lfloor \frac{t + d - t_0}{\Delta t} \right\rfloor + 1,$$

donde t_0 es el tiempo mínimo observado en el dataset. Los contactos se agrupan por `t_start` para construir los grafos instantáneos $G_t = (V, E_t)$. En la implementación, esto se materializa como un diccionario

`by_t = {t ↦ DataFrame de contactos con t_start = t}`,

que permite acceder rápidamente a los contactos activos en cada ventana temporal.

VIII-B. Simulación del modelo SIS sobre la red temporal

La dinámica SIS se implementa explícitamente en el cuaderno `sis_animacion.ipynb`. Primero se cargan los nodos y contactos:

```
nodes = pd.read_csv(P / "nodes.csv")
contacts = pd.read_csv(P / "contacts.csv")
nodes["id"] = nodes["id"].astype(str)
contacts["source"] = contacts["source"].astype(str)
contacts["target"] = contacts["target"].astype(str)
```

Los parámetros epidemiológicos se fijan como

$$\beta = 0,5, \quad \delta = 0,02,$$

donde β es la probabilidad de contagio por ventana y δ la probabilidad de recuperación por ventana. Adicionalmente se

define un calendario de siembra (brotes exógenos) como un diccionario

$$\text{seed_schedule} = \{0 \mapsto 10, 40 \mapsto 50, 120 \mapsto 25\},$$

que indica cuántos individuos susceptibles se infectan aleatoriamente en los tiempos $t = 0, 40, 120$.

El horizonte temporal se determina a partir del máximo `t_end` en los contactos:

$$T = \text{máx}\{t_{\text{end}}\}.$$

El estado de cada nodo se almacena en un diccionario

$$\text{state}[v] \in \{0, 1\}, \quad 0 = S \text{ (susceptible)}, \quad 1 = I \text{ (infectado)},$$

inicialmente con todos los nodos en S . Se utiliza un generador aleatorio reproducible `rng = Random(11)`. La función

```
def reseed(k):
    S = [v for v, s in state.items() if s == 0]
    for v in rng.sample(S, min(k, len(S))):
        state[v] = 1
```

infecta aleatoriamente k susceptibles, y se invoca tanto en $t = 0$ como en los demás tiempos de `seed_schedule`.

El ciclo de simulación recorre las ventanas $t = 1, \dots, T$. En cada paso se ejecutan dos etapas:

1. **Recuperaciones** $I \rightarrow S$. Para cada nodo infectado v , se genera $U \sim \text{Unif}(0, 1)$; si $U < \delta$, se actualiza `state[v] := 0`.
2. **Contagios** $S \rightarrow I$. Se consulta `by_t[t]` para obtener los contactos activos y se construye el grafo G_t . Para cada nodo susceptible v con al menos un vecino infectado, se calcula el tiempo total de exposición

$$w_{\text{total}}(v, t) = \sum_{(u, v) \in E_t} w_t(u, v),$$

usando la columna `weight`. Se aproxima el número de bloques efectivos de exposición como

$$\text{blocks} = \text{máx}\{1, \text{round}(w_{\text{total}}/20)\}.$$

La probabilidad acumulada de infección en la ventana se modela como

$$p_{\text{inf}}(v, t) = 1 - (1 - \beta)^{\text{blocks}},$$

que corresponde a sufrir `blocks` exposiciones independientes con probabilidad β . Si un número aleatorio $U < p_{\text{inf}}(v, t)$, se escoge aleatoriamente uno de los vecinos infectados $u \in N_I(v, t)$ como fuente del contagio y se añade el par (u, v) a una lista de nuevas infecciones de la ventana.

Al final de cada ventana, todas las nuevas infecciones se aplican simultáneamente, y se registra el evento de contagio añadiendo una tupla (u, v, t) a la lista `infection_edges`. Además, se contabiliza el número de susceptibles e infectados, almacenando tripletas (t, S_t, I_t) en la lista `series`.

Al terminar el bucle se construyen los `DataFrame` finales:

- `inf`: DataFrame construido a partir de `infection_edges`, con las columnas `source`, `target` y `t_infect`.
- `series`: DataFrame construido a partir de la lista `series`, con las columnas `t`, `S` e `I`.

Estos se guardan en `results/infection_edges.csv` y `results/states_by_t.csv`, respectivamente, y sirven como base tanto para el grafo de contagios como para las curvas temporales $I(t)$.

VIII-C. Red de contagios dirigida y visualización

A partir de `infection_edges.csv` se construye el grafo de contagios dirigido

$$G_{\text{inf}} = (V, E_{\text{inf}}),$$

donde $(u, v) \in E_{\text{inf}}$ significa que el individuo u infectó a v en el instante `t_infect`. En el notebook se calcula además, para cada nodo, el tiempo de *primera infección*

$$t_{\text{mín}}(v) = \min\{t_{\text{infect}} : (\cdot, v, t_{\text{infect}}) \in \text{inf}\},$$

almacenado como un diccionario `first_inf`.

Para visualizar la expansión del brote se define una función `draw_snapshot(t_cut)` que:

- toma el subconjunto de aristas con `t_infect` $\leq t_{\text{cut}}$,
- construye un `DiGraph` H con todos los nodos en V y solo esas aristas,
- asigna a cada nodo un color según su tiempo de primera infección, utilizando un mapa de color continuo (plasma) normalizado entre el mínimo y máximo de `t_infect`,
- dibuja el grafo con un *layout* por fuerzas (`spring_layout`) y una barra de color que actúa como leyenda de los tiempos de infección.

Los nodos que aún no se han infectado para t_{cut} se pintan en gris, mientras que los ya infectados reciben un color más intenso cuanto más tardía fue su infección. Con esto se generan *snapshots* de la red de contagios en distintos cortes de tiempo, proporcionando una representación visual de las rutas de propagación y de la aparición de posibles supercontagadores.

VIII-D. Alcanzabilidad temporal, umbral estático y sesgo por agregación

El notebook incluye además un experimento complementario para conectar la dinámica SIS con la teoría de umbrales epidémicos en redes estáticas y para cuantificar el sesgo introducido por la agregación temporal.

Paciente cero aproximado y TBFS temporal: A partir de `inf` se identifica una aproximación al *paciente cero* como la fuente de la arista de contagio más temprana: el nodo que aparece en la columna `source` de la fila cuyo valor en `t_infect` es mínimo.

Desde este nodo se corre un *Temporal Breadth-First Search* (TBFS) sobre los contactos `contacts`, que calcula para cada vértice v el tiempo de primera llegada $t_{\text{temporal}}(v)$ respetando el orden temporal de las ventanas (es decir, solo se pueden usar aristas activas en tiempos no decrecientes).

El algoritmo mantiene un diccionario `arrival[v]` inicializado en $+\infty$ salvo para el nodo `paciente0`, y una cola de pares (v, t) que se expande explorando las aristas de las ventanas $t' \geq t$. Al finalizar, se construye un DataFrame `tbfs_df` con las columnas `id` y `t_temporal`, donde los nodos no alcanzables reciben valor `NaN`.

Grafo agregado estático y umbral epidémico: A partir de contactos se construye también un grafo agregado no dirigido G_{agg} , en el que se coloca una arista $\{u, v\}$ si hubo al menos un contacto entre u y v en algún instante. Sobre este grafo se calcula la matriz de adyacencia A y su mayor autovalor $\lambda_{\text{máx}}$. En el marco de redes estáticas, el umbral epidémico aproximado para un proceso SIS viene dado por

$$\tau_c \approx \frac{1}{\lambda_{\text{máx}}}.$$

En la implementación se compara este umbral con el valor efectivo

$$\tau = \frac{\beta}{\delta}$$

inducido por los parámetros de simulación. Si $\tau < \tau_c$, la teoría lineal en redes estáticas sugeriría que la epidemia no debería sostenerse; si $\tau \geq \tau_c$, la red agregada admite un régimen endémico. Esta comparación sirve para contrastar la predicción estática con el comportamiento observado en la simulación sobre la red temporal.

TBFS “coarse” y efecto de la agregación temporal: Finalmente, el notebook implementa una variante *coarse* del TBFS que agrupa las ventanas temporales en bloques (bins) de tamaño `bin_size` (medido en número de ventanas de 20s). Para un tamaño de bin dado, se definen intervalos

$$B_k = \{t : (k-1) \cdot \text{bin_size} \leq t < k \cdot \text{bin_size}\},$$

y se dice que un nodo v es alcanzable en el bin k si existe una cadena de contactos internos a dicho bin que conecta a v con algún nodo ya alcanzable en un bin anterior o en el mismo bin.

La función `tbfs_coarse(bin_size)` devuelve, para cada vértice, el primer bin b en el que puede ser alcanzado desde el paciente cero, o $+\infty$ si nunca se alcanza. A partir de este resultado se define el conjunto de nodos alcanzables en la versión agregada por bins como el conjunto de vértices cuyo tiempo de llegada *coarse* es finito.

Por otro lado, el TBFS original sobre la red temporal fina produce el conjunto de nodos alcanzables a partir de los tiempos de llegada temporales. Comparando ambos conjuntos se puede medir cuántos nodos aparecen falsamente alcanzables sólo debido a la agregación; es decir, cuántos vértices son alcanzables en el esquema *coarse* pero no lo son en el TBFS fino.

En el experimento se barren varios tamaños de bin (por ejemplo `bin_size` en $\{1, 2, 5, 10\}$) y se construye una tabla `delta_df` con las columnas:

- `bin_size`: tamaño de bin en número de ventanas,
- `reach_original`: número de nodos alcanzables en el TBFS fino,




Figura 1. Evolución temporal del número de infectados I_t en la red temporal bajo el modelo SIS con $\beta = 0,5$ y $\delta = 0,02$.

- `reach_coarse`: número de nodos alcanzables en el TBFS coarse,
- `extra_nodes`: cantidad de nodos que se vuelven alcanzables sólo por efecto del coarse-graining.

Finalmente se grafica `reach_coarse` en función de `bin_size`, junto con una línea horizontal que marca `reach_original`. Este gráfico ilustra cómo, al aumentar el tamaño de la ventana de agregación Δt , se tiende a sobreestimar el conjunto de nodos alcanzables desde el paciente cero, mostrando empíricamente el sesgo que introduce la agregación temporal discutida en el marco teórico.

IX. RESULTADOS

En esta sección presentamos los resultados de la simulación del modelo SIS sobre la red de contactos temporal, la estructura del grafo de contagios dirigido, las medidas de centralidad sobre dicha red y la comparación entre la dinámica temporal y su versión agregada estática.

IX-A. Evolución temporal de susceptibles e infectados

La simulación se ejecutó sobre un total de $T = 36477$ ventanas temporales de 20s cada una, con una población de $N = 180$ individuos. La serie temporal `states_by_t.csv` registra, para cada ventana t , el número de susceptibles S_t e infectados I_t .

En la Fig. 1 se muestra la evolución de I_t a lo largo del tiempo. Al inicio del experimento, la población parte aproximadamente con $I_1 = 10$ infectados y $S_1 = 170$ susceptibles, producto del primer pulso de siembra exógena. El número de infectados crece hasta alcanzar un máximo de

$$I_{\text{máx}} \approx 60$$

alrededor de la ventana $t \approx 450$, lo que corresponde a un tercio de la población ($\sim 33\%$). A partir de ese máximo, la epidemia entra en un régimen de oscilaciones y, conforme se agotan los contactos y operan los eventos de recuperación, el sistema retorna gradualmente a un estado libre de infección, con $I_t = 0$ e $S_t = 180$ hacia el final del horizonte temporal.

En términos cualitativos, las curvas $S(t)$ e $I(t)$ muestran un brote inicial pronunciado seguido de una extinción de la epidemia en la escala temporal del experimento, a pesar de que




Figura 2. Visualización del grafo de contagios G_{inf} , donde el color de cada nodo codifica el tiempo de primera infección. Se aprecia la expansión del brote a través de distintas ramas de contagio.

los parámetros (β, δ) corresponden a un régimen supercrítico en el modelo estático (véase la subsección de comparación con el grafo agregado).

IX-B. Grafo de contagios dirigido y visualización del brote

A partir del archivo `infection_edges.csv` se construyó el grafo de contagios dirigido G_{inf} , donde cada arista (u, v) representa un evento de contagio desde u hacia v en un tiempo t_{infect} . En total se registran 375 eventos de infección, que involucran a 88 nodos distintos ya sea como fuente o como destino de contagios.

La Fig. 2 muestra una visualización de la red de contagios coloreando los nodos según su tiempo de primera infección. Los nodos que se infectan tempranamente aparecen en tonos fríos, mientras que los infectados tardíos se muestran en tonos cálidos. Se observan “cascadas” de contagio que parten de unos pocos nodos iniciales y se expanden hacia el resto de la red, así como regiones que permanecen poco afectadas durante gran parte del horizonte temporal.

Para ilustrar la propagación local en momentos concretos, la Fig. 3 presenta algunos snapshots representativos del grafo de contagios, cada uno truncado hasta un tiempo de infección distinto. Se aprecia cómo, a medida que avanza el tiempo, nuevas componentes se activan y el brote penetra en regiones que inicialmente permanecían sin casos.

IX-C. Nodos influyentes: centralidad en contactos vs. contagios

Para estudiar qué individuos son estructuralmente críticos en la propagación se calcularon medidas de centralidad sobre dos redes distintas:




Figura 3. Snapshots del grafo de contagios para distintos cortes temporales ($t = 40, 255, 471, 902$). Se observa cómo el brote va activando gradualmente diferentes regiones de la red.

1. el grafo agregado de contactos G_{agg} , construido a partir de `contacts.csv` uniendo todos los contactos observados entre pares de individuos;
2. el grafo de contagios dirigido G_{inf} , construido a partir de `infection_edges.csv`.

Sobre el grafo de contactos G_{agg} se ordenaron los nodos según su *grado de contacto* total. Los cinco nodos con mayor grado son, por ejemplo,

94, 62, 18, 119, 32,

donde el nodo 94 alcanza 56 contactos totales. Estos individuos pueden interpretarse como hubs estructurales: son quienes tienen más encuentros en la red global.

Sobre el grafo de contagios G_{inf} se construyó un ranking de “supercontagiadores” a partir del grado de salida (número de contagios directos realizados) y medidas adicionales como PageRank. Los cinco nodos con mayor número de contagios directos (`out_degree`) incluyen, por ejemplo,

168, 158, 8, 62, 154,

donde el nodo 168 alcanza alrededor de 16 contagios directos, seguido por el nodo 158 con cerca de 12 contagios.

La Fig. 4 ilustra la relación entre la centralidad de PageRank y la ocurrencia de contagios: los nodos de alto PageRank en el grafo de contactos tienden a concentrar una parte importante de los eventos de infección, pero no existe una correspondencia perfecta entre “tener muchos contactos” y “ser el principal difusor”. De hecho, de los cinco nodos con mayor grado de contacto, sólo el nodo 62 aparece también entre los que más contagian, lo que refuerza la importancia de la posición temporal y estructural de los individuos.

Adicionalmente, la Fig. 5 muestra el grafo de contagios superpuesto a la estructura de contactos agregada, lo que permite visualizar cómo los contagios se canalizan preferentemente a través de ciertas regiones de la red, y no de manera uniforme.




Figura 4. Relación entre centralidad de PageRank y contagios: los nodos con mayor PageRank en el grafo de contactos se superponen con los eventos de infección observados en el grafo de contagios.




Figura 5. Grafo de contagios superpuesto a la red de contactos agregada, destacando las regiones estructuralmente relevantes para la transmisión.

IX-D. TBFS temporal y tiempos de llegada

A partir del grafo de contactos temporal se ejecutó un *Temporal Breadth-First Search* (TBFS) considerando como aproximación de paciente cero al nodo que aparece como fuente en el evento de contagio más temprano registrado en `infection_edges.csv`. El TBFS calcula, para cada nodo v , el tiempo mínimo de llegada $t_{temporal}(v)$ respetando la causalidad temporal de los contactos.

Los resultados se almacenan en un `DataFrame` `tbfs_df` con las columnas `id` (identificador del nodo) y `t_temporal` (tiempo de primera llegada). En la Tabla I se muestra un extracto del resultado, en el mismo formato que la salida

Tabla I

EJEMPLO DE TIEMPOS MÍNIMOS DE LLEGADA OBTENIDOS CON TBFS. SE MUESTRAN ÚNICAMENTE ALGUNAS DE LAS PRIMERAS Y ÚLTIMAS FILAS DEL DATAFRAME `TBFS_DF`, EN UN FORMATO ANÁLOGO A LA SALIDA ABREVIADA DE `PANDAS`.

idx	id	t _{temporal}
0	149	0
1	155	24
2	157	40
3	169	131
4	158	160
	:	
175	52	9433
176	132	9542
177	6	17298
178	22	34579
179	27	35347

abreviada de `pandas`, donde sólo se presentan algunas de las primeras filas y de las últimas filas del DataFrame.

Los resultados del DataFrame muestran que:

- todos los nodos de la red son alcanzables temporalmente desde el paciente cero dentro del horizonte observado;
- los tiempos de llegada se distribuyen en un rango amplio: los primeros contagios indirectos más allá del paciente cero aparecen en ventanas tempranas, mientras que los últimos nodos se alcanzan sólo hacia el final del intervalo de observación.

Esta dispersión temporal contrasta con la estructura topológica del grafo agregado, donde la distancia mínima (en número de saltos) entre el paciente cero y cualquier otro nodo es pequeña (a lo sumo tres). En términos puramente estáticos, la red parece “pequeña”, pero la dimensión temporal introduce restricciones fuertes sobre cuándo esos caminos son realmente utilizables para la propagación.

IX-E. Comparación con el grafo agregado y umbral epidémico

Sobre el grafo agregado no dirigido G_{agg} se construyó la matriz de adyacencia A y se calculó su mayor autovalor $\lambda_{\text{máx}}$. Para este dataset, se obtiene un valor de orden

$$\lambda_{\text{máx}} \approx 30,14,$$

lo que implica un umbral epidémico estático

$$\tau_c \approx \frac{1}{\lambda_{\text{máx}}} \approx 0,033.$$

Con los parámetros de simulación utilizados, el cociente

$$\tau = \frac{\beta}{\delta} = \frac{0,5}{0,02} = 25$$

es muy superior a τ_c , por lo que la teoría lineal en redes estáticas sugeriría un régimen claramente endémico en el que la infección podría sostenerse de manera indefinida.

Sin embargo, la simulación SIS sobre la red temporal (Fig. 1) muestra un comportamiento distinto: aunque se observan brotes importantes (con un máximo de $I_{\text{máx}} \approx 60$

infectados simultáneos), la epidemia acaba extinguiéndose en el horizonte considerado y el sistema retorna al estado libre de infección ($I_t = 0$). Este contraste resalta que el criterio de umbral basado en el grafo agregado tiende a sobreestimar la capacidad de la red para sostener una epidemia cuando la estructura de contactos es fuertemente dinámica y limitada en el tiempo.

Además, la comparación entre los tiempos de llegada del TBFS temporal y las distancias mínimas en el grafo agregado muestra que el modelo estático subestima sistemáticamente los tiempos de propagación: aunque en el grafo agregado muchos nodos están a pocos saltos del paciente cero, en la red temporal algunos sólo se vuelven alcanzables tras un número considerable de ventanas temporales.

En conjunto, estas figuras y resultados cuantifican el sesgo introducido al ignorar la dimensión temporal: el grafo agregado sugiere una red altamente conectada y rápidamente transmisible, mientras que la red dinámica revela una propagación más lenta y condicionada por la sincronización efectiva de los contactos.

IX-F. Efecto de la agregación temporal en la alcanzabilidad

Para estudiar la robustez de los resultados de alcanzabilidad frente a la agregación temporal, se consideró una variante *coarse* del TBFS en la que las ventanas de 20s se agrupan en bloques (bins) de tamaño `bin_size` (medido en número de ventanas). Para cada `bin_size` se definieron intervalos

$$B_k = \{t : (k-1) \cdot \text{bin_size} \leq t < k \cdot \text{bin_size}\},$$

y se dijo que un nodo v es alcanzable en el bin k si existe una cadena de contactos internos a dicho bin que conecta a v con algún nodo ya alcanzable en un bin anterior o en el mismo bin.

Para cada valor de `bin_size` se calculó, a partir de esta dinámica *coarse*, el conjunto de nodos alcanzables desde el paciente cero y se comparó con el conjunto obtenido mediante el TBFS fino sobre todas las ventanas. A partir de estos resultados se construyó un DataFrame `delta_df` con las columnas:

- `bin_size`: tamaño de bin en número de ventanas,
- `reach_original`: número de nodos alcanzables en el TBFS fino,
- `reach_coarse`: número de nodos alcanzables en el TBFS *coarse*,
- `extra_nodes`: cantidad de nodos que se vuelven alcanzables sólo por efecto del *coarse-graining*.

La Tabla II resume los valores obtenidos. Se observa que, para todos los tamaños de bin considerados, el número de nodos alcanzables y el número de nodos “extra” coinciden exactamente con el resultado original: la agregación temporal en estos rangos de `bin_size` no altera la alcanzabilidad desde el paciente cero.

La Fig. 6 muestra `reach_coarse` en función de `bin_size`, junto con una línea horizontal que marca `reach_original`. En este caso, todas las curvas coinciden: para los tamaños de bin estudiados, la agregación temporal no

Tabla II
ALCANZABILIDAD TEMPORAL DESDE EL PACIENTE CERO BAJO DISTINTOS
TAMAÑOS DE BIN. EL NÚMERO DE NODOS ALCANZABLES Y DE NODOS
EXTRA SE MANTIENE CONSTANTE PARA TODOS LOS VALORES DE
BIN_SIZE CONSIDERADOS.

bin_size	reach_original	reach_coarse	extra_nodes
1	180	180	0
5	180	180	0
10	180	180	0
100	180	180	0
1000	180	180	0




Figura 6. Efecto de la agregación temporal en la alcanzabilidad desde el paciente cero. Se representa el número de nodos alcanzables ($reach_coarse$) en función de bin_size , junto con la referencia $reach_original$. En este caso, las curvas coinciden para todos los tamaños de bin considerados.

introduce nodos falsamente alcanzables desde el paciente cero, lo que sugiere cierta robustez del resultado de alcanzabilidad frente al coarse-graining.

X. CONCLUSIONES

El objetivo general de este trabajo fue modelar y analizar la propagación de epidemias en redes dinámicas mediante teoría de grafos. A partir de los resultados obtenidos, podemos establecer las siguientes conclusiones, en relación directa con los objetivos específicos propuestos.

En primer lugar, respecto al objetivo de *representar matemáticamente una red dinámica mediante nodos y aristas variables en el tiempo*, se logró construir una red temporal ponderada a partir del conjunto de datos de contactos cara a cara en un colegio. La familia de grafos $\mathcal{G} = \{G_t\}$ permitió capturar la variación de los contactos en el tiempo, mientras que la discretización en ventanas de 20 s y la construcción del diccionario de snapshots facilitaron tanto la simulación como el análisis de alcanzabilidad temporal. Esta modelación hizo posible distinguir explícitamente entre caminos estáticos y caminos que respetan la causalidad temporal.

En segundo lugar, en cuanto a la *adaptación de un modelo epidemiológico clásico (SIS) al contexto de redes dinámicas*, se implementó un proceso SIS en tiempo discreto donde la probabilidad de infección depende de los contactos activos en cada ventana y de su intensidad (duración). La simulación

mostró brotes epidémicos significativos, con un máximo de aproximadamente $I_{\max} \approx 60$ infectados simultáneos (cerca del 33 % de la población), seguidos por una extinción de la epidemia en el horizonte observado. Este comportamiento evidencia cómo, incluso con parámetros (β, δ) que en el modelo estático ubicarían al sistema en un régimen fuertemente supercrítico, la dinámica temporal de los contactos puede limitar la persistencia de la infección.

En tercer lugar, en relación con el objetivo de *identificar cómo los cambios en la estructura de la red afectan la velocidad y el alcance de la propagación*, los resultados sobre el grafo de contagios dirigido, las medidas de centralidad y el TBFS permiten extraer varias conclusiones:

- La comparación entre los hubs de contacto en el grafo agregado G_{agg} y los principales “supercontagadores” en el grafo de contagios G_{inf} muestra que tener muchos contactos no es suficiente para ser el principal difusor de la epidemia. Sólo algunos nodos (como el 62) aparecen simultáneamente en ambos rankings, lo que indica que la posición estructural y el momento en que ocurren los contactos son tan relevantes como el número total de interacciones.
- El TBFS temporal revela que, aunque en el grafo agregado las distancias en número de saltos entre el paciente cero y el resto de la red son pequeñas, los tiempos mínimos de llegada se distribuyen en un rango amplio, con nodos que sólo se vuelven alcanzables hacia el final del intervalo de observación. Esto pone de manifiesto que la estructura temporal de los contactos ralentiza y canaliza la propagación, en contraste con la visión excesivamente conectada sugerida por el grafo estático.
- El contraste entre el umbral epidémico estático $\tau_c \approx 1/\lambda_{\max}$ y el cociente $\tau = \beta/\delta$ evidencia un sesgo importante: mientras que el grafo agregado sugiere un régimen claramente endémico, la simulación sobre la red temporal muestra que la epidemia se extingue. En otras palabras, ignorar la dimensión temporal lleva a sobreestimar la capacidad de la red para sostener una infección.

Finalmente, con respecto al objetivo de *diseñar y ejecutar una simulación computacional que ilustre el fenómeno*, se desarrolló una implementación completa en Python que integra: (i) construcción de la red temporal de contactos, (ii) simulación del modelo SIS con siembras exógenas, (iii) generación del grafo de contagios dirigido, (iv) cálculo de centralidades y umbral epidémico estático, y (v) análisis de alcanzabilidad mediante TBFS fino y su variante coarse. Las figuras incluidas (curva $I(t)$, snapshots del brote, overlays con PageRank y gráfica del efecto de la agregación temporal) ilustran de manera clara cómo se propaga la epidemia en la red y cómo se relacionan los distintos niveles de modelado.

El experimento de coarse-graining temporal aporta además una conclusión metodológica: para los tamaños de bin considerados, la alcanzabilidad desde el paciente cero se mantiene invariante, lo que sugiere cierta robustez de las conclusiones

respecto a la granularidad temporal empleada. No obstante, la discrepancia entre el comportamiento observado en la red temporal y las predicciones basadas en el grafo agregado muestra que la dimensión temporal no puede despreciarse al estudiar procesos epidémicos en redes reales.

En conjunto, los resultados obtenidos muestran que la teoría de grafos aplicada a redes dinámicas, complementada con modelos epidemiológicos como SIS y herramientas de análisis computacional, permite capturar aspectos esenciales de la propagación de epidemias que no pueden ser explicados adecuadamente desde un enfoque puramente estático.

X-A. Limitaciones y trabajo futuro

Este trabajo presenta varias limitaciones que abren líneas claras de investigación futura. En primer lugar, se analizó un único conjunto de datos (contactos en un colegio) con una resolución temporal fija ($\Delta t = 20$ s), sin estudiar cómo cambian los resultados al variar la granularidad temporal ni al considerar otros contextos (hogares, transporte, redes laborales, etc.). Además, los parámetros epidemiológicos (β , δ) se eligieron con fines ilustrativos, sin calibración con datos reales. Como trabajo futuro, sería interesante incorporar otros modelos (SIR, SEIR), explorar distintos conjuntos de datos, estudiar estrategias de control basadas en centralidad o estructura temporal y construir mapas de comportamiento del sistema en función de (β , δ , Δt).

REFERENCIAS

- Borgatti, S. P. (2005). Centrality and network flow. *Social Networks*, 27(1), 55–71. doi: 10.1016/j.socnet.2004.11.008
- Brin, S., y Page, L. (1998). The anatomy of a large-scale hypertextual web search engine. En *Proceedings of the seventh international world wide web conference*.
- Bui-Xuan, B.-M., Ferreira, A., y Jarry, A. (2003). Computing shortest, fastest, and foremost journeys in dynamic networks. En *International conference on research in networking* (pp. 442–453). doi: 10.1007/3-540-44804-7_35
- Casteigts, A., Flocchini, P., Quattrociocchi, W., y Santoro, N. (2012). Time-varying graphs and dynamic networks. *International Journal of Parallel, Emergent and Distributed Systems*, 27(5), 387–408. doi: 10.1080/17445760.2012.668546
- Harvey, W. T., Carabelli, A. M., Jackson, B., y cols. (2021). Sars-cov-2 variants, spike mutations and immune escape. *Nature Reviews Microbiology*, 19, 409–424.
- Holme, P. (2015). Modern temporal network theory: A colloquium. *The European Physical Journal B*, 88, 234. doi: 10.1140/epjb/e2015-60357-4
- Holme, P., y Saramäki, J. (2012). Temporal networks. *Physics Reports*, 519(3), 97–125. doi: 10.1016/j.physrep.2012.03.001
- Kiss, I. Z., Miller, J. C., y Simon, P. L. (2017). *Mathematics of epidemics on networks: From exact to approximate models*. Cham: Springer. doi: 10.1007/978-3-319-50806-1
- Kitsak, M., Gallos, L. K., Havlin, S., y cols. (2010). Identification of influential spreaders in complex networks. *Nature Physics*, 6, 888–893. doi: 10.1038/nphys1746
- Liu, Y., Gayle, A. A., Wilder-Smith, A., y Rocklöv, J. (2020). The reproductive number of covid-19 is higher compared to sars coronavirus. *Journal of Travel Medicine*, 27(2).
- Masuda, N., y Lambiotte, R. (2016). *A guide to temporal networks*. Singapore: World Scientific. doi: 10.1142/9714
- Newman, M. E. J. (2010). *Networks: An introduction*. Oxford, UK: Oxford University Press. doi: 10.1093/acprof:oso/9780199206650.001.0001
- Pastor-Satorras, R., Castellano, C., Van Mieghem, P., y Vespignani, A. (2015). Epidemic processes in complex networks. *Reviews of Modern Physics*, 87(3), 925–979. doi: 10.1103/RevModPhys.87.925
- Rocha, L. E., y Masuda, N. (2016). Random walk centrality for temporal networks. *New Journal of Physics*, 18(9), 093030. doi: 10.1088/1367-2630/18/9/093030
- Van Mieghem, P. (2011). *Graph spectra for complex networks*. Cambridge: Cambridge University Press. doi: 10.1017/CBO9780511975418